



Universitatea
Transilvania
din Brașov

FACULTATEA DE MATEMATICĂ
ȘI INFORMATICĂ

LUCRARE DE DIPLOMĂ

Absolvent: Manea Alexandru
Coordonator: Conf. dr. Sasu Lucian Mircea
Asist. univ. dr. Maria Nuțu

Brașov
Iunie 2024



Universitatea
Transilvania
din Brașov

FACULTATEA DE MATEMATICĂ
ȘI INFORMATICĂ

LUCRARE DE DIPLOMĂ

To be determined

Absolvent: Manea Alexandru
Coordonator: Conf. dr. Sasu Lucian Mircea
Asist. univ. dr. Maria Nuțu

Brașov
Iunie 2024

Cuprins

| | | |
|----------|--|----------|
| 1 | Introducere | 2 |
| 1.1 | Scurtă descriere a temei | 2 |
| 1.2 | Motivația alegerii temei | 3 |
| 1.3 | Contribuții personale în lucrare | 3 |
| 1.4 | Structura lucrării | 4 |
| 2 | Detalierea temei | 5 |
| 2.1 | Implementarea și Evaluarea Modelului de Rețea Neurală | 5 |
| 2.1.1 | Prelucrarea Datelor și Pregătirea Modelului | 5 |
| 2.1.2 | Arhitectura Modelului | 5 |
| 2.1.3 | Antrenarea și Evaluarea Modelului | 6 |
| 2.2 | State-of-the-Art și Perspective în Predicțiile Economice | 6 |
| 2.2.1 | Abordări Similare și Diferențierea Modelului Nostru | 6 |
| 2.3 | Concluzii Intermediare | 6 |
| 3 | Titlu capitol | 8 |
| 4 | Titlu capitol | 9 |

Capitolul 1

Introducere

1.1 Scurtă descriere a temei

În ultimele decenii, progresul tehnologic și accesibilitatea crescută la date de mare volum au transformat radical modul în care informațiile economice sunt analizate și interpretate. În acest context, lucrarea de față își propune să exploreze și să demonstreze cum tehnologiile de învățare automată, și în particular rețelele neurale, pot fi aplicate pentru a efectua predicții economice precise și relevante. Abordând această temă, lucrarea vizează dezvoltarea unei aplicații capabile să prelucereze seturi de date complexe și să ofere predicții asupra unor indicatori economici cheie, cum ar fi rata inflației.

Predicția economică, în esența sa, implică analiza tendințelor istorice și a relațiilor dintre diferiți indicatori pentru a anticipa evoluțiile viitoare ale pieței. Utilizând un set de date cuprinzător, care include indicatori precum Indicele Prețurilor de Consum (CPI), Indicele Prețurilor Producătorilor (PPI) și Cheltuielile pentru Consum Personal (PCE), această lucrare își propune să aplice modele de învățare automată pentru a identifica și înțelege modelele care stau la baza dinamicii economice. Prin analiza și interpretarea acestor date, modelul dezvoltat urmărește să ofere o metodologie fiabilă și eficientă de predicție, contribuind astfel la îmbunătățirea deciziilor în domeniul economic.

Această abordare se distinge prin capacitatea sa de a procesa și analiza cantități masive de date într-un mod care ar fi fost de neconceput cu câteva decenii în urmă, deschizând noi orizonturi în domeniul analizei economice. În plus, prin aplicarea tehnologiilor avansate de învățare automată, lucrarea își propune să depășească limitările metodologiilor tradiționale de predicție, oferind astfel perspective noi și mai precise asupra viitorului economic.

1.2 Motivația alegerii temei

Alegerea acestei teme a fost profund influențată de importanța și impactul pe care predicțiile economice le au asupra societății moderne. Într-un climat economic global caracterizat prin volatilitate și incertitudine, capacitatea de a oferi predicții precise și timpurii este mai valoroasă ca niciodată. Deciziile de politică economică, strategiile de investiții și planificarea financiară a gospodăriilor depind în mod crucial de anticiparea corectă a tendințelor economice. Astfel, îmbunătățirea acurateței și fiabilității acestor predicții poate avea un impact semnificativ asupra economiei la nivel macro și micro.

În plus, fascinația pentru potențialul tehnologiilor de învățare automată și inteligență artificială în a transforma și optimiza procesele tradiționale a constituit un alt factor decisiv în alegerea acestei direcții de cercetare. Învățarea automată oferă unelte puternice pentru analiza datelor complexe, deschizând posibilitatea de a descoperi modele și corelații care ar putea rămâne neobservate prin metode analitice standard. Prin aplicarea acestor tehnologii în domeniul economic, lucrarea își propune nu doar să contribuie la dezvoltarea teoretică și practică a predicțiilor economice, ci și să demonstreze cum inovațiile în IA pot fi folosite pentru a adresa unele dintre cele mai presante provocări ale lumii contemporane.

Motivația pentru această temă decurge, așadar, din dorința de a explora noi frontiere științifice și de a aduce o contribuție semnificativă la îmbunătățirea modului în care informațiile economice sunt analizate și utilizate în luarea deciziilor. Prin această lucrare, aspir la a arăta cum tehnologia poate juca un rol esențial în modelarea viitorului economic, oferind instrumente mai precise și mai eficiente pentru anticiparea schimbărilor din piață.

1.3 Contribuții personale în lucrare

Lucrarea își propune să contribuie la domeniul predicțiilor economice prin mai multe aspecte inovatoare:

- Dezvoltarea unei arhitecturi de rețea neurală adaptată specific pentru analiza datelor economice și predicția indicatorilor cheie.
- Implementarea unui proces de prelucrare și normalizare a datelor, esențial pentru îmbunătățirea performanței modelului de învățare automată.
- Evaluarea comparativă a modelului dezvoltat față de alte metode de predicție, oferind o perspectivă asupra eficienței și acurateței acestuia.

Aceste contribuții subliniază abordarea personală și inovația adusă în cadrul lucrării, reflectând implicarea activă în explorarea și aplicarea tehnologiilor de învățare automată în economie.

1.4 Structura lucrării

Lucrarea este structurată astfel încât să ofere o abordare logică și cuprinzătoare a temei, distribuită pe mai multe capitole:

1. **Capitolul 2** introduce conceptele teoretice și revizuirea literaturii, punând bazele necesare înțelegerii domeniului predicțiilor economice și a tehnologiilor de învățare automată.
2. **Capitolul 3** descrie metodologia de cercetare utilizată, inclusiv selecția datelor, preprocesarea acestora și detaliile tehnice ale implementării modelului de rețea neurală.

Capitolul 2

Detalierea temei

2.1 Implementarea și Evaluarea Modelului de Rețea Neurală

După cum a fost prezentat anterior, modelul nostru utilizează o arhitectură de rețea neurală concepută pentru a învăța din complexitatea datelor economice și a oferi predicții precise asupra ratei inflației. Acest segment detaliază procesul de implementare și evaluare a modelului, punând accent pe specificitățile și provocările întâmpinate în dezvoltarea acestuia.

2.1.1 Prelucrarea Datelor și Pregătirea Modelului

Prelucrarea datelor joacă un rol crucial în performanța modelului de învățare automată. În cazul nostru, datele sunt mai întâi normalizate folosind `StandardScaler` din `scikit-learn`, pentru a asigura că toate caracteristicile au aceeași scară de importanță în procesul de învățare. Împărțirea setului de date în subseturi de antrenament și testare permite evaluarea performanței modelului pe date nevăzute, asigurând o estimare realistă a capacității sale de generalizare.

2.1.2 Arhitectura Modelului

Modelul nostru este construit folosind `PyTorch`, o bibliotecă populară pentru învățare automată, care oferă flexibilitate și putere în definirea și antrenarea modelelor de rețele neurale. Arhitectura aleasă este adaptată pentru a capta relațiile complexe dintre variabilele economice, constând din mai multe straturi ascunse care permit modelului să învețe reprezentări la nivel înalt ale datelor. Selecția numărului de straturi și a neuronilor, precum și a funcțiilor de activare, a fost re-

alizată prin experimentare și validare încrucișată, pentru a optimiza acuratețea predicțiilor.

2.1.3 Antrenarea și Evaluarea Modelului

Antrenarea modelului implică ajustarea ponderilor rețelei neurale prin retro-propagare și optimizare, folosind un set de date de antrenament. Am aplicat tehnici precum regularizarea și dropout-ul pentru a preveni supraajustarea, asigurând că modelul nostru generalizează bine pe date nevăzute. Evaluarea performanței se face pe baza setului de testare, utilizând metrici precum eroarea medie pătratică (MSE) pentru a măsura precizia predicțiilor modelului în raport cu valorile reale ale ratei inflației.

2.2 State-of-the-Art și Perspective în Predicțiile Economice

Comparând modelul nostru cu abordările state-of-the-art în domeniul predicțiilor economice, observăm că rețelele neurale și, în special, cele profunde oferă un avantaj semnificativ în termeni de capacitate de modelare și flexibilitate. Modelele de învățare profundă au fost aplicate cu succes în diverse domenii ale predicțiilor economice, de la prognozarea piețelor financiare până la anticiparea indicatorilor macroeconomici.

2.2.1 Abordări Similare și Diferențierea Modelului Nostru

În literatura de specialitate, există numeroase studii care aplică rețele neurale pentru predicții economice. Diferențierea principală a modelului nostru constă în adaptarea specifică a arhitecturii rețelei și în procesul de prelucrare a datelor, concepute pentru a maximiza relevanța și acuratețea în contextul specific al ratei inflației. De asemenea, abordarea noastră pune un accent deosebit pe interpretabilitatea modelului, încercând să oferim nu doar predicții precise, ci și insight-uri asupra relațiilor dintre variabilele economice studiate.

2.3 Concluzii Intermediare

Modelul de rețea neurală prezentat în această lucrare demonstrează potențialul învățării automate de a revoluționa domeniul predicțiilor economice. Prin abordarea specifică adoptată și prin concentrarea pe date economice relevante,

lucrarea contribuie la extinderea cunoștințelor în acest domeniu, oferind o metodologie robustă pentru analiza și predicția ratelor inflației. Perspectivele viitoare includ extinderea modelului pentru a include mai mulți indicatori economici și testarea pe seturi de date din diferite contexte geografice și temporale, pentru a valida și îmbunătăți generalizabilitatea și acuratețea predicțiilor.

Capitolul 3

Titlu capitol

Capitolul 4

Titlu capitol